

第1章 随机事件及其概率

(1) 排列组合公式

$P_m^n = \frac{m!}{(m-n)!}$ 从 m 个人中挑出 n 个人进行排列的可能数。

$C_m^n = \frac{m!}{n!(m-n)!}$ 从 m 个人中挑出 n 个人进行组合的可能数。

(2) 加法原理和乘法原理

加法原理 (两种方法均能完成此事): $m+n$

某件事由两种方法来完成, 第一种方法可由 m 种方法完成, 第二种方法可由 n 种方法来完成, 则这件事可由 $m+n$ 种方法来完成。

乘法原理 (两个步骤分别不能完成这件事): $m \times n$

某件事由两个步骤来完成, 第一个步骤可由 m 种方法完成, 第二个步骤可由 n 种方法来完成, 则这件事可由 $m \times n$ 种方法来完成。

(3) 一些常见排列

重复排列和非重复排列 (有序); 对立事件 (至少有一个); 圆排列; 顺序问题

(4) 随机试验和随机事件

如果一个试验在相同条件下可以重复进行, 而每次试验的可能结果不止一个, 但在进行一次试验之前却不能断言它出现哪个结果, 则称这种试验为随机试验。

试验的可能结果称为随机事件。

(5) 基本事件、样本空间和事件

在一个试验下, 不管事件有多少个, 总可以从其中找出这样一组事件, 它具有如下性质:

① 每进行一次试验, 必须发生且只能发生这一组中的一个事件;

② 任何事件, 都是由这一组中的部分事件组成的。

这样一组事件中的每一个事件称为基本事件, 用 $\{\omega\}$ 来表示。

基本事件的全体, 称为试验的样本空间, 用 Ω 表示。

一个事件就是由 Ω 中的部分点 (样本点 ω) 组成的集合。通常用大写字母 A, B, C, \dots 表示事件, 它们是 Ω 的子集。

Ω 为必然事件, \emptyset 为不可能事件。

不可能事件 (\emptyset) 的概率为零, 而概率为零的事件不一定是不可事件; 同理, 必然事件 (Ω) 的概率为 1, 而概率为 1 的事件也不一定是必然事件。

(6) 事件的关系与运算

① 关系:

如果事件 A 的组成部分也是事件 B 的组成部分, (A 发生必有事件 B 发生), 记为 $A \subset B$

如果同时有 $A \subset B, B \subset A$, 则称事件 A 与事件 B 等价, 或称 A 等于 B , 记为 $A=B$ 。

A, B 中至少有一个发生的事件, 记为 $A \cup B$, 或者 $A+B$ 。

属于 A 而不属于 B 的部分所构成的事件, 称为 A 与 B 的差, 记为 $A-B$, 也可表示为 $A-AB$ 或者 $A\bar{B}$, 它表示 A 发生而 B 不发生的事件。

A, B 同时发生: $A \cap B$, 或者 AB 。 $A \cap B = \emptyset$, 则表示 A 与 B 不可能同时发生, 称事件 A 与事件 B 互不相容或者互斥。基本事件是互不相容的。

$\Omega-A$ 称为事件 A 的逆事件, 或称 A 的对立事件, 记为 \bar{A} 。它表示 A 不发生的事件。互斥未必对立。

② 运算:

结合率: $A(BC)=(AB)C$ $A \cup (B \cup C)=(A \cup B) \cup C$

分配率: $(AB) \cup C=(A \cup C) \cap (B \cup C)$ $(A \cup B) \cap C=(AC) \cup (BC)$

德摩根率: $\overline{\bigcap_{i=1}^{\infty} A_i} = \bigcup_{i=1}^{\infty} \overline{A_i}$ $\overline{A \cup B} = \overline{A} \cap \overline{B}$, $\overline{A \cap B} = \overline{A} \cup \overline{B}$

(7) 概率的公理化定义

设 Ω 为样本空间, A 为事件, 对每一个事件 A 都有一个实数 $P(A)$, 若满足下列三个条件:

1° $0 \leq P(A) \leq 1$,

2° $P(\Omega) = 1$

3° 对于两两互不相容的事件 A_1, A_2, \dots , 有可列 (完全) 可加性:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

则称 $P(A)$ 为事件 A 的概率。

(8) 古典概型

1° $\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$,

2° $P\{\omega_1\} = P\{\omega_2\} = \dots = P\{\omega_n\} = \frac{1}{n}$ 。

设任一事件 A , 它是由 $\omega_1, \omega_2, \dots, \omega_m$ 组成的, 则有

$$P(A) = P\{\omega_1, \omega_2, \dots, \omega_m\} = \frac{m}{n} = \frac{A \text{ 所包含的基本事件数}}{\text{基本事件总数}}$$

(9) 几何概型

若随机试验的结果为无限不可数并且每个结果出现的可能性均匀, 同时样本空间中的每一个基本事件可以使用一个有界区域来描述, 则称此随机试验为几何概型。对任一事件 A , $P(A) = \frac{L(A)}{L(\Omega)}$ 。其中 L 为几何度量 (长度、面积、体积)。

(10) 加法公式

$$P(A+B) = P(A) + P(B) - P(AB)$$

当 $P(AB)=0$ 时, $P(A+B)=P(A)+P(B)$

(11) 概率的单调性

$$P(A-B) = P(A) - P(AB)$$

当 $B \subset A$ 时, $P(A-B)=P(A)-P(B)$

当 $A=\Omega$ 时, $P(\overline{B})=1-P(B)$

(12) 条件概率

定义 设 A, B 是两个事件, 且 $P(A)>0$, 则称

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为事件 A 发生条件下, 事件 B 发生的条件概率。

条件概率是概率的一种, 所有概率的性质都适合于条件概率。例如

$$P(\Omega|B)=1 \Rightarrow P(\overline{B}|A)=1-P(B|A)$$

(13) 乘法公式

$$P(AB) = P(A)P(B|A)$$

更一般地, 对事件 A_1, A_2, \dots, A_n , 若 $P(A_1 A_2 \dots A_{n-1})>0$, 则有

$$P(A_1 A_2 \dots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \dots P(A_n|A_1 A_2 \dots A_{n-1})。$$

(14) 独立性

①两个事件的独立性

设事件 A, B 满足 $P(AB) = P(A)P(B)$, 则称事件 A, B 是相互独立的。

若事件 A, B 相互独立, 且 $P(A)>0$, 则有

$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(A)P(B)}{P(A)} = P(B)$$

若事件 A 、 B 相互独立, 则可得到 \bar{A} 与 B 、 A 与 \bar{B} 、 \bar{A} 与 \bar{B} 也都相互独立。

必然事件 Ω 和不可能事件 \emptyset 与任何事件都相互独立。

\emptyset 与任何事件都互斥。

②多个事件的独立性

设 ABC 是三个事件, 如果满足两两独立的条件,

$$P(AB)=P(A)P(B); P(BC)=P(B)P(C); P(CA)=P(C)P(A)$$

并且同时满足 $P(ABC)=P(A)P(B)P(C)$ 。那么 A 、 B 、 C 相互独立。

对于 n 个事件类似。

(15) 全概率公式

设事件组 B_1, B_2, \dots, B_n 满足

1° B_1, B_2, \dots, B_n 两两互不相容, $P(B_i) > 0 (i=1, 2, \dots, n)$,

2° $A \subset \bigcup_{i=1}^n B_i$,

则有

$$P(A) = P(B_1)P(A|B_1) + P(B_2)P(A|B_2) + \dots + P(B_n)P(A|B_n)。$$

(16) 贝叶斯公式

设事件组 B_1, B_2, \dots, B_n 及 A 满足

1° B_1, B_2, \dots, B_n 两两互不相容, $P(B_i) > 0, i=1, 2, \dots, n$,

2° $A \subset \bigcup_{i=1}^n B_i, P(A) > 0$,

则

$$P(B_i|A) = \frac{P(B_i)P(A|B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)}, i=1, 2, \dots, n。$$

此公式即为贝叶斯公式。

$P(B_i)$, ($i=1, 2, \dots, n$), 通常叫先验概率。 $P(B_i|A)$, ($i=1, 2, \dots, n$), 通常称为后验概率。贝叶斯公式反映了“因果”的概率规律, 并作出了“由果溯因”的推断。

(17)

用 p 表示每次试验 A 发生的概率, 则 \bar{A} 发生的概率为 $1-p=q$, 用 $P_n(k)$ 表示 n 重伯努利试验中 A 出现 $k(0 \leq k \leq n)$ 次的概率,

$$P_n(k) = C_n^k p^k q^{n-k}, k=0, 1, 2, \dots, n。$$

第二章 随机变量及其分布

(1) 离散型随机变量的分布律

设离散型随机变量 X 的可能取值为 $X_k(k=1, 2, \dots)$ 且取各个值的概率, 即事件 $(X=X_k)$ 的概率为

$$P(X=x_k)=p_k, k=1, 2, \dots,$$

则称上式为离散型随机变量 X 的概率分布或分布律。有时也用分布列的形式给出:

$$\begin{array}{c|c} X & x_1, x_2, \dots, x_k, \dots \\ \hline P(X=x_k) & p_1, p_2, \dots, p_k, \dots \end{array}$$

显然分布律应满足下列条件:

$$(1) p_k \geq 0, \quad k = 1, 2, \dots, \quad (2) \sum_{k=1}^{\infty} p_k = 1.$$

(2) 连续型随机变量的分布密度

设 $F(x)$ 是随机变量 X 的分布函数, 若存在非负函数 $f(x)$, 对任意实数 x , 有

$$F(x) = \int_{-\infty}^x f(x) dx,$$

则称 X 为连续型随机变量。 $f(x)$ 称为 X 的概率密度函数或密度函数, 简称概率密度。密度函数具有下面 2 个性质:

$$1^\circ \quad f(x) \geq 0. \quad 2^\circ \quad \int_{-\infty}^{+\infty} f(x) dx = 1.$$

(3) 离散与连续型随机变量的关系

$$P\{X = x\} \approx P(x < X \leq x + dx) \approx f(x) dx$$

积分微元 $f(x) dx$ 在连续型随机变量理论中所起的作用与 $P(X = x_k) = p_k$ 在离散型随机变量理论中所起的作用相类似。

(4) 分布函数

设 X 为随机变量, x 是任意实数, 则函数

$$F(x) = P\{X \leq x\}$$

称为随机变量 X 的分布函数, 本质上是一个累积函数。

$P\{a < X \leq b\} = F(b) - F(a)$ 可以得到 X 落入区间 $(a, b]$ 的概率。分布函数 $F(x)$ 表示随机变量落入区间 $(-\infty, x]$ 内的概率。

分布函数具有如下性质:

$$1^\circ \quad 0 \leq F(x) \leq 1, \quad -\infty < x < +\infty;$$

$$2^\circ \quad F(x) \text{ 是单调不减的函数, 即 } x_1 < x_2 \text{ 时, 有 } F(x_1) \leq F(x_2);$$

$$3^\circ \quad F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0, \quad F(+\infty) = \lim_{x \rightarrow +\infty} F(x) = 1;$$

$$4^\circ \quad F(x+0) = F(x), \text{ 即 } F(x) \text{ 是右连续的};$$

$$5^\circ \quad P\{X = x\} = F(x) - F(x-0).$$

对于离散型随机变量, $F(x) = \sum_{x_k \leq x} p_k$;

对于连续型随机变量, $F(x) = \int_{-\infty}^x f(x) dx$ 。

(5) 八大分布

0-1 分布 (贝努利试验)	$P\{X=1\}=p, \quad P\{X=0\}=q$ $p+q=1$
-------------------	---

二项分布 (伯努利概型: n 次独立重复进 行的贝努利试验, 即: ① 每次试验 中 A 发生的概率 每次均一样; ② 每次试验是独立 的, 也即每次试验 A 发生与否与其 他次试验 A 发生 与否是互不影响 的。 这种试验称为伯 努利概型, 或称为 n 重伯努利试 验。)	在 n 重贝努里试验中, 设事件 A 发生的概率为 p 。事件 A 发 生的次数是随机变量设为 X , 则 X 可能取值为 $0, 1, 2, \dots, n$ 。 X 的分布律为 $P\{X=k\} = P_n(k) = C_n^k p^k q^{n-k},$ 其中 $q=1-p, 0 < p < 1, k=0, 1, 2, \dots, n$, 则称随机变量 X 服从参数为 n, p 的二项分布。记为 $X \sim B(n, p)。$ 当 $n=1$ 时, $P\{X=k\} = p^k q^{1-k}, k=0, 1$, 这就是 (0-1) 分布, 所以 (0-1) 分布是二项分布的特例。 当 n 很大, p 很小时, 二项分布的极限分布可近似泊松分布 $P(\lambda)$ ($np=\lambda, n \rightarrow \infty$)。 当 n 很大, 由中心极限定理可以, 二项分布的极限分布可近似 正态分布 $N(np, npq)$ 。
泊松分布	设随机变量 X 的分布律为 $P\{X=k\} = \frac{\lambda^k}{k!} e^{-\lambda}, \lambda > 0, k=0, 1, 2, \dots,$ 则称随机变量 X 服从参数为 λ 的泊松分布, 记为 $X \sim P(\lambda)$ 。
超几何分布	N 个球中有 $M(M < N)$ 个红球, 余下为白球, 从中任取 $n(n < N)$ 个球, n 个球中的红球数为 X , 则 X 的分布律为 $P\{X=k\} = \frac{C_M^k \cdot C_{N-M}^{n-k}}{C_N^n},$ 其中 $k=0, 1, 2, \dots, l, l = \min(M, n)$ 也称随机变量 X 服从参数为 n, N, M 的超几何分布, 记为 $H(n, N, M)$ 。
几何分布	n 重贝努里试验, 事件 A 首次发生时的试验次数 X 的分布律 为 $P\{X=k\} = q^{k-1} p, k=1, 2, 3, \dots,$ 其中 $p \geq 0, q=1-p$ 。 随机变量 X 服从参数为 p 的几何分布, 记为 $G(p)$ 。
均匀分布	设随机变量 X 的值只落在 $[a, b]$ 内, 其密度函数 $f(x)$ 为 $f(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{其它} \end{cases}$ 则称随机变量 X 在 $[a, b]$ 上服从均匀分布, 记为 $X \sim U(a, b)$ 。 分布函数为 $F(x) = \int_{-\infty}^x f(t) dt = \begin{cases} 0 & x < a \\ \frac{b-x}{b-a} & a \leq x < b \\ 1 & x \geq b \end{cases}$ 当 $a \leq x_1 < x_2 \leq b$ 时, X 落在区间 (x_1, x_2) 内的概率为 $P\{x_1 < X < x_2\} = \frac{x_2 - x_1}{b - a}。$

指数分布	$f(x) = \begin{cases} \lambda e^{-\lambda x} & 0 \leq x \\ 0 & x < 0 \end{cases}$ <p>其中 $\lambda > 0$, 则称随机变量 X 服从参数为 λ 的指数分布。 X 的分布函数为</p> $F(x) = \int_{-\infty}^x f(t)dt = \begin{cases} 1 - e^{-\lambda x} & x > 0 \\ 0 & x < 0 \end{cases}$ <p>记住积分公式:</p> $\int_0^{\infty} x^n e^{-x} dx = n!$
正态分布	<p>设随机变量 X 的密度函数为</p> $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < +\infty,$ <p>其中 $\mu, \sigma > 0$ 为常数, 则称随机变量 X 服从参数为 μ, σ^2 的正态分布或高斯 (Gauss) 分布, 记为 $X \sim N(\mu, \sigma^2)$。 $f(x)$ 具有如下性质: 1° $f(x)$ 的图形是关于 $x = \mu$ 对称的; 2° 当 $x = \mu$ 时, $f(\mu) = \frac{1}{\sqrt{2\pi}\sigma}$ 为最大值; 若 $X \sim N(\mu, \sigma^2)$, 则 X 的分布函数为</p> $F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$ <p>参数 $\mu = 0, \sigma = 1$ 时的正态分布称为标准正态分布, 记为 $X \sim N(0,1)$, 其密度函数记为</p> $\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad -\infty < x < +\infty,$ <p>分布函数为</p> $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt。$ <p>$\Phi(x)$ 是不可求积函数, 其函数值, 已编制成表可供查用。 $\Phi(-x) = 1 - \Phi(x)$ 且 $\Phi(0) = \frac{1}{2}$。 如果 $X \sim N(\mu, \sigma^2)$, 则 $\frac{X - \mu}{\sigma} \sim N(0,1)$。 $P(x_1 < X \leq x_2) = \Phi\left(\frac{x_2 - \mu}{\sigma}\right) - \Phi\left(\frac{x_1 - \mu}{\sigma}\right)。$</p>

(6) 分位数

下侧分位数: $P\{X \leq \mu_\alpha\} = \alpha$;

上侧分位数: $P\{X > \mu_\alpha\} = \alpha$ 。

第三章 二维随机变量及其分布

(1) 联合分布

离散型	<p>如果二维随机向量 $\xi=(X, Y)$ 的所有可能取值为至多可列个有序对 (x,y) , 则称 ξ 为离散型随机量。</p> <p>设 $\xi= (X, Y)$ 的所有可能取值为 $(x_i, y_j)(i, j=1,2,\cdots)$, 且事件 $\{\xi= (x_i, y_j)\}$ 的概率为 p_{ij},称</p> $P\{(X,Y)=(x_i, y_j)\}= p_{ij}(i, j=1,2,\cdots)$ <p>为 $\xi= (X, Y)$ 的分布律或称为 (X, Y) 的联合分布律。</p> <p>联合分布有时也用下面的概率分布表来表示:</p> <table> <tr> <th>$\begin{matrix} Y \\ \backslash \\ X \end{matrix}$</th> <th>$y_1$</th> <th>$y_2$</th> <th>$\cdots$</th> <th>$y_j$</th> <th>$\cdots$</th> </tr> <tr> <th>$x_1$</th> <td>$p_{11}$</td> <td>$p_{12}$</td> <td>$\cdots$</td> <td>$p_{1j}$</td> <td>$\cdots$</td> </tr> <tr> <th>$x_2$</th> <td>$p_{21}$</td> <td>$p_{22}$</td> <td>$\cdots$</td> <td>$p_{2j}$</td> <td>$\cdots$</td> </tr> <tr> <th>$\vdots$</th> <td>$\vdots$</td> <td>$\vdots$</td> <td></td> <td>$\vdots$</td> <td>$\vdots$</td> </tr> <tr> <th>$x_i$</th> <td>$p_{i1}$</td> <td></td> <td>$\cdots$</td> <td>$p_{ij}$</td> <td>$\cdots$</td> </tr> <tr> <th>$\vdots$</th> <td>$\vdots$</td> <td>$\vdots$</td> <td></td> <td>$\vdots$</td> <td>$\vdots$</td> </tr> </table> <p>这里 p_{ij} 具有下面两个性质:</p> <p>(1) $p_{ij} \geq 0 \ (i, j=1,2,\cdots)$; (2) $\sum_i \sum_j p_{ij} = 1.$</p>	$\begin{matrix} Y \\ \backslash \\ X \end{matrix}$	y_1	y_2	\cdots	y_j	\cdots	x_1	p_{11}	p_{12}	\cdots	p_{1j}	\cdots	x_2	p_{21}	p_{22}	\cdots	p_{2j}	\cdots	\vdots	\vdots	\vdots		\vdots	\vdots	x_i	p_{i1}		\cdots	p_{ij}	\cdots	\vdots	\vdots	\vdots		\vdots	\vdots
$\begin{matrix} Y \\ \backslash \\ X \end{matrix}$	y_1	y_2	\cdots	y_j	\cdots																																
x_1	p_{11}	p_{12}	\cdots	p_{1j}	\cdots																																
x_2	p_{21}	p_{22}	\cdots	p_{2j}	\cdots																																
\vdots	\vdots	\vdots		\vdots	\vdots																																
x_i	p_{i1}		\cdots	p_{ij}	\cdots																																
\vdots	\vdots	\vdots		\vdots	\vdots																																
连续型	<p>对于二维随机向量 $\xi=(X,Y)$, 如果存在非负函数 $f(x,y)(-\infty < x < +\infty, -\infty < y < +\infty)$,使对任意一个其邻边分别平行于坐标轴的矩形区域 D , 即 $D=\{(X,Y) a < x < b, c < y < d\}$ 有</p> $P\{(X,Y) \in D\} = \iint_D f(x,y) dx dy,$ <p>则称 ξ 为连续型随机向量; 并称 $f(x,y)$ 为 $\xi=(X, Y)$ 的分布密度或称为 (X,Y) 的联合分布密度。</p> <p>分布密度 $f(x,y)$ 具有下面两个性质:</p> <p>(1) $f(x,y) \geq 0$; (2) $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x,y) dx dy = 1.$</p>																																				

(2) 二维随机变量的本质

$$\{X=x, Y=y\} = \{X=x\} \cap \{Y=y\}$$

(3) 联合分布函数

设 (X, Y) 为二维随机变量, 对于任意实数 x, y , 二元函数

$$F(x, y) = P\{X \leq x, Y \leq y\}$$

称为二维随机向量 (X, Y) 的联合分布函数。

联合分布函数 $F(x, y)$ 是一个以全平面为其定义域, 以事件 $\{(\omega_1, \omega_2) | -\infty < X(\omega_1) \leq x, -\infty < Y(\omega_2) \leq y\}$ 的概率为函数值的一个实值函数。

分布函数 $F(x, y)$ 具有以下的基本性质:

(1) $0 \leq F(x, y) \leq 1$;

(2) $F(x, y)$ 分别对 x 和 y 是非减的, 即

当 $x_2 > x_1$ 时, 有 $F(x_2, y) \geq F(x_1, y)$; 当 $y_2 > y_1$ 时, 有 $F(x, y_2) \geq F(x, y_1)$;

(3) $F(x, y)$ 分别对 x 和 y 是右连续的, 即

$$F(x, y) = F(x+0, y), F(x, y) = F(x, y+0);$$

(4) $F(-\infty, -\infty) = F(-\infty, y) = F(x, -\infty) = 0, F(+\infty, +\infty) = 1.$

(5) 对于 $x_1 < x_2, y_1 < y_2$, 有

$$F(x_2, y_2) - F(x_2, y_1) - F(x_1, y_2) + F(x_1, y_1) \geq 0.$$

(4) 离散型与连续型的关系

$$P\{X=x, Y=y\} \approx P\{x < X \leq x+dx, y < Y \leq y+dy\} \approx f(x, y)dxdy$$

(5) 边缘分布

离散型	X 的边缘分布为 $P_{i\bullet} = P(X = x_i) = \sum_j p_{ij} (i, j = 1, 2, \dots);$ Y 的边缘分布为 $P_{\bullet j} = P(Y = y_j) = \sum_i p_{ij} (i, j = 1, 2, \dots)。$
连续型	X 的边缘分布密度为 $f_X(x) = \int_{-\infty}^{+\infty} f(x, y)dy;$ Y 的边缘分布密度为 $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y)dx.$

(6) 条件分布

离散型	在已知 $X=x_i$ 的条件下, Y 取值的条件分布为 $P\{Y = y_j X = x_i\} = \frac{p_{ij}}{p_{i\bullet}};$ 在已知 $Y=y_j$ 的条件下, X 取值的条件分布为 $P\{X = x_i Y = y_j\} = \frac{p_{ij}}{p_{\bullet j}},$
连续型	在已知 $Y=y$ 的条件下, X 的条件分布密度为 $f(x y) = \frac{f(x, y)}{f_Y(y)};$ 在已知 $X=x$ 的条件下, Y 的条件分布密度为 $f(y x) = \frac{f(x, y)}{f_X(x)}$

(7) 独立性

一般型	$F(X, Y) = F_X(x) F_Y(y)$
离散型	$p_{ij} = p_{i\bullet} p_{\bullet j}$ 有零不独立
连续型	$f(x, y) = f_X(x) f_Y(y)$ 直接判断, 充要条件: ①可分离变量 ②正概率密度区间为矩形
二维正态分布	$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \left(\frac{y-\mu_2}{\sigma_2}\right)^2\right]},$ $\rho = 0$
随机变量的函数	若 $X_1, X_2, \dots, X_m, X_{m+1}, \dots, X_n$ 相互独立, h, g 为连续函数, 则: $h(X_1, X_2, \dots, X_m)$ 和 $g(X_{m+1}, \dots, X_n)$ 相互独立。 特例: 若 X 与 Y 独立, 则: $h(X)$ 和 $g(Y)$ 独立。 例如: 若 X 与 Y 独立, 则: $3X+1$ 和 $5Y-2$ 独立。

(8) 二维均匀分布

设随机向量 (X, Y) 的分布密度函数为

$$f(x, y) = \begin{cases} \frac{1}{S_D} & (x, y) \in D \\ 0, & \text{其他} \end{cases}$$

其中 S_D 为区域 D 的面积, 则称 (X, Y) 服从 D 上的均匀分布, 记为 $(X, Y) \sim U(D)$ 。

例如图 3.1、图 3.2 和图 3.3。




图 3.1




图 3.3




图 3.2

(9) 二维正态分布

设随机向量 (X, Y) 的分布密度函数为

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \left(\frac{y-\mu_2}{\sigma_2}\right)^2\right]},$$

其中 $\mu_1, \mu_2, \sigma_1 > 0, \sigma_2 > 0, |\rho| < 1$ 是 5 个参数, 则称 (X, Y) 服从二维正态分布,

记为 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$.

由边缘密度的计算公式, 可以推出二维正态分布的两个边缘分布仍为正态分布,

即 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$.

但是若 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, (X, Y) 未必是二维正态分布。

(10) 函数分布

一维随机变 量的函数	离散型	<p>已知 X 的分布列为</p> <table><tr><td>X</td><td>$x_1, x_2, \cdots, x_n, \cdots$</td></tr><tr><td>$P(X = x_i)$</td><td>$p_1, p_2, \cdots, p_n, \cdots$</td></tr></table> <p>$Y = g(X)$ 的分布列 ($y_i = g(x_i)$ 互不相等) 如下:</p> <table><tr><td>Y</td><td>$g(x_1), g(x_2), \cdots, g(x_n), \cdots$</td></tr><tr><td>$P(Y = y_i)$</td><td>$p_1, p_2, \cdots, p_n, \cdots$</td></tr></table> <p>若有某些 $g(x_i)$ 相等, 则应将对应的 p_i 相加作为 $g(x_i)$ 的概率。</p>	X	$x_1, x_2, \cdots, x_n, \cdots$	$P(X = x_i)$	$p_1, p_2, \cdots, p_n, \cdots$	Y	$g(x_1), g(x_2), \cdots, g(x_n), \cdots$	$P(Y = y_i)$	$p_1, p_2, \cdots, p_n, \cdots$
	X	$x_1, x_2, \cdots, x_n, \cdots$								
$P(X = x_i)$	$p_1, p_2, \cdots, p_n, \cdots$									
Y	$g(x_1), g(x_2), \cdots, g(x_n), \cdots$									
$P(Y = y_i)$	$p_1, p_2, \cdots, p_n, \cdots$									
	连续型	<p>先利用 X 的概率密度 $f_X(x)$ 写出 Y 的分布函数</p> $F_Y(y) = P(g(X) \leq y) = \int_{g(x) \leq y} f(x) dx,$ <p>再利用变上下限积分的求导公式求出 $f_Y(y)$。</p>								

二维随机变量的函数	离散型	<p>设随机变量(X, Y)是离散型随机变量, 其分布律分别为</p> $P\{X=x_i, Y=y_j\}=p_{ij} \quad i, j=1,2,\dots$ <p>$Z=G(X, Y)$是随机变量, 则 Z 的分布律为</p> $P\{Z=z_k\}=P\{G(X, Y)=z_k\}$ $=\sum_{(x_i, y_j) \in T_k} P\{X=x_i, Y=y_j\}, \quad k=1,2,\dots$ <p>其中 $T_k=\{(x_i, y_j) G(x_i, y_j)=z_k\}$。</p>
	连续型	<p>先求出 Z 的分布函数 $F_Z(z)$</p> $F_Z(z)=P\{Z \leq z\}=P\{G(X, Y) \leq z\}$ $=\iint_{\{(x,y): G(x,y) \leq z\}} f(x,y) dx dy$ <p>对 $F_Z(z)$ 微分得到 $f_Z(z)$。</p>
$Z=X+Y$		<p>根据定义计算: $F_Z(z)=P(Z \leq z)=P(X+Y \leq z)$</p> <p>对于连续型, $f_Z(z)=\int_{-\infty}^{+\infty} f(x, z-x) dx$</p> <p>两个独立的正态分布的和仍为正态分布 $(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$。</p> <p>$n$ 个相互独立的正态分布的线性组合, 仍服从正态分布。</p> $\mu = \sum_i C_i \mu_i, \quad \sigma^2 = \sum_i C_i^2 \sigma_i^2$
$Z=X/Y$		<p>根据定义计算: $F_Z(z)=P(Z \leq z)=P(X/Y \leq z)$</p> <p>对于连续型, $f_z(x)=\int_{-\infty}^{+\infty} y f(zy, y) dy$</p>
$Z=\max(X_1, X_2, \dots, X_n)$ 和 $Z=\min(X_1, X_2, \dots, X_n)$		<p>若 X_1, X_2, \dots, X_n 相互独立, 其分布函数分别为 $F_{x_1}(x), F_{x_2}(x), \dots, F_{x_n}(x)$, 则它们的分布函数分别为:</p> $F_{\max}(x) = F_{x_1}(x) \cdot F_{x_2}(x) \cdot \dots \cdot F_{x_n}(x)$ $F_{\min}(x) = 1 - [1 - F_{x_1}(x)] \cdot [1 - F_{x_2}(x)] \cdot \dots \cdot [1 - F_{x_n}(x)]$
χ^2 分布		<p>设 n 个随机变量 X_1, X_2, \dots, X_n 相互独立, 且服从标准正态分布, 可以证明它们的平方和</p> $W = \sum_{i=1}^n X_i^2$ <p>的分布密度为</p> $f(u) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} u^{\frac{n}{2}-1} e^{-\frac{u}{2}} & u \geq 0, \\ 0, & u < 0. \end{cases}$ <p>我们称随机变量 W 服从自由度为 n 的 χ^2 分布, 记为 $W \sim \chi^2(n)$, 其中</p> $\Gamma\left(\frac{n}{2}\right) = \int_0^{+\infty} x^{\frac{n}{2}-1} e^{-x} dx.$ <p>所谓自由度是指独立正态随机变量的个数, 它是随机变量分布中的一个重要参数。</p> <p>χ^2 分布满足可加性: 设 $Y_i \sim \chi^2(n_i)$, 则</p> $Z = \sum_{i=1}^k Y_i \sim \chi^2(n_1 + n_2 + \dots + n_k).$

t 分布	<p>设 X, Y 是两个相互独立的随机变量, 且 $X \sim N(0,1), Y \sim \chi^2(n)$, 可以证明函数</p> $T = \frac{X}{\sqrt{Y/n}}$ <p>的概率密度为</p> $f(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \quad (-\infty < t < +\infty).$ <p>我们称随机变量 T 服从自由度为 n 的 t 分布, 记为 $T \sim t(n)$。 $t_{1-\alpha}(n) = -t_{\alpha}(n)$</p>
F 分布	<p>设 $X \sim \chi^2(n_1), Y \sim \chi^2(n_2)$, 且 X 与 Y 独立, 可以证明 $F = \frac{X/n_1}{Y/n_2}$ 的概率密度函数为</p> $f(y) = \begin{cases} \frac{\Gamma(\frac{n_1+n_2}{2})}{\Gamma(\frac{n_1}{2})\Gamma(\frac{n_2}{2})} \left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}} y^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2}y\right)^{-\frac{n_1+n_2}{2}}, & y \geq 0 \\ 0, & y < 0 \end{cases}$ <p>我们称随机变量 F 服从第一个自由度为 n_1, 第二个自由度为 n_2 的 F 分布, 记为 $F \sim F(n_1, n_2)$。 $F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$</p>

第四章 随机变量的数字特征

(1) 一维随机变量的数字特征

	离散型	连续型
期望 期望就是平均值	<p>设 X 是离散型随机变量, 其分布律为 $P(X = x_k) = p_k, k=1,2,\dots$</p> $E(X) = \sum_{k=1}^{\infty} x_k p_k$ <p>(要求绝对收敛)</p>	<p>设 X 是连续型随机变量, 其概率密度为 $f(x)$,</p> $E(X) = \int_{-\infty}^{+\infty} x f(x) dx$ <p>(要求绝对收敛)</p>
函数的期望	<p>$Y=g(X)$</p> $E(Y) = \sum_{k=1}^{\infty} g(x_k) p_k$	<p>$Y=g(X)$</p> $E(Y) = \int_{-\infty}^{+\infty} g(x) f(x) dx$
方差 $D(X)=E\{[X-E(X)]^2\}$, 标准差 $\sigma(X)=\sqrt{D(X)}$, ,	$D(X) = \sum_k [x_k - E(X)]^2 p_k$	$D(X) = \int_{-\infty}^{+\infty} [x - E(X)]^2 f(x) dx$

矩	<p>①对于正整数 k, 称随机变量 X 的 k 次幂的数学期望为 X 的 k 阶原点矩, 记为 ν_k, 即</p> $\nu_k = E(X^k) = \sum_i x_i^k p_i, k=1, 2, \dots$ <p>②对于正整数 k, 称随机变量 X 与 $E(X)$ 差的 k 次幂的数学期望为 X 的 k 阶中心矩, 记为 μ_k, 即</p> $\mu_k = E(X - E(X))^k$ $= \sum_i (x_i - E(X))^k p_i, k=1, 2, \dots$	<p>①对于正整数 k, 称随机变量 X 的 k 次幂的数学期望为 X 的 k 阶原点矩, 记为 ν_k, 即</p> $\nu_k = E(X^k) = \int_{-\infty}^{+\infty} x^k f(x) dx,$ $k=1, 2, \dots$ <p>②对于正整数 k, 称随机变量 X 与 $E(X)$ 差的 k 次幂的数学期望为 X 的 k 阶中心矩, 记为 μ_k, 即</p> $\mu_k = E[(X - E(X))^k]$ $= \int_{-\infty}^{+\infty} (x - E(X))^k f(x) dx,$ $k=1, 2, \dots$
切比雪夫不等式	<p>设随机变量 X 具有数学期望 $E(X)=\mu$, 方差 $D(X)=\sigma^2$, 则对于任意正数 ε, 有下列切比雪夫不等式</p> $P\{ X - \mu \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$ <p>切比雪夫不等式给出了在未知 X 的分布的情况下, 对概率</p> $P\{ X - \mu \geq \varepsilon\}$ <p>的一种估计, 它在理论上具有重要意义。</p>	

(2) 期望的性质

一、 $E(C)=C$

二、 $E(CX)=CE(X)$

三、 $E(X+Y)=E(X)+E(Y)$, $E(\sum_{i=1}^n C_i X_i) = \sum_{i=1}^n C_i E(X_i)$

四、 $E(XY)=E(X)E(Y)$, 充分条件: X 和 Y 独立; 充要条件: X 和 Y 不相关。

(3) 方差的性质

一、 $D(C)=0$; $E(C)=C$

二、 $D(aX)=a^2D(X)$; $E(aX)=aE(X)$

三、 $D(aX+b)=a^2D(X)$; $E(aX+b)=aE(X)+b$

四、 $D(X)=E(X^2)-E^2(X)$

五、 $D(X \pm Y)=D(X)+D(Y)$, 充分条件: X 和 Y 独立; 充要条件: X 和 Y 不相关。

$D(X \pm Y)=D(X)+D(Y) \pm 2E[(X-E(X))(Y-E(Y))]$, 无条件成立。

而 $E(X+Y)=E(X)+E(Y)$, 无条件成立。

(4) 常见分布的期望和方差

	期望	方差
0-1 分布 $B(1, p)$	p	$p(1-p)$
二项分布 $B(n, p)$	np	$np(1-p)$
泊松分布 $P(\lambda)$	λ	λ
几何分布 $G(p)$	$\frac{1}{p}$	$\frac{1-p}{p^2}$

超几何分布 $H(n, M, N)$	$\frac{nM}{N}$	$\frac{nM}{N} \left(1 - \frac{M}{N}\right) \left(\frac{N-n}{N-1}\right)$
均匀分布 $U(a, b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
正态分布 $N(\mu, \sigma^2)$	μ	σ^2
χ^2 分布	n	$2n$
t 分布	0	$\frac{n}{n-2} (n>2)$

(5) 二维随机变量的数字特征

期望	$E(X) = \sum_{i=1}^{\infty} x_i p_{i\bullet}$ $E(Y) = \sum_{j=1}^{\infty} y_j p_{\bullet j}$	$E(X) = \int_{-\infty}^{+\infty} x f_X(x) dx$ $E(Y) = \int_{-\infty}^{+\infty} y f_Y(y) dy$
函数的期望	$E[G(X, Y)] = \sum_i \sum_j G(x_i, y_j) p_{ij}$	$E[G(X, Y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} G(x, y) f(x, y) dx dy$
方差	$D(X) = \sum_i [x_i - E(X)]^2 p_{i\bullet}$ $D(Y) = \sum_j [y_j - E(Y)]^2 p_{\bullet j}$	$D(X) = \int_{-\infty}^{+\infty} [x - E(X)]^2 f_X(x) dx$ $D(Y) = \int_{-\infty}^{+\infty} [y - E(Y)]^2 f_Y(y) dy$
协方差	<p>对于随机变量 X 与 Y, 称它们的二阶混合中心矩 μ_{11} 为 X 与 Y 的协方差或相关矩, 记为 σ_{XY} 或 $\text{cov}(X, Y)$, 即</p> $\text{cov}(X, Y) = E[(X - E(X))(Y - E(Y))].$ <p>与记号 σ_{XY} 相对应, X 与 Y 的方差 $D(X)$ 与 $D(Y)$ 也可分别记为 σ_{XX} 与 σ_{YY}。</p>	

相关系数	<p>对于随机变量 X 与 Y, 如果 $D(X)>0, D(Y)>0$, 则称</p> $\frac{\text{cov}(X,Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$ <p>为 X 与 Y 的相关系数, 记作 ρ_{XY} (有时可简记为 ρ)。</p> <p>$\rho \leq 1$, 当 $\rho =1$ 时, 称 X 与 Y 完全相关: $P\{X=aY+b\}=1$</p> <p>完全相关 $\begin{cases} \text{正相关, 当 } \rho=1 \text{ 时 } (a>0), \\ \text{负相关, 当 } \rho=-1 \text{ 时 } (a<0), \end{cases}$</p> <p>而当 $\rho=0$ 时, 称 X 与 Y 不相关。</p> <p>以下五个命题是等价的:</p> <p>① $\rho_{XY}=0$; ② $\text{cov}(X,Y)=0$; ③ $E(XY)=E(X)E(Y)$; ④ $D(X+Y)=D(X)+D(Y)$; ⑤ $D(X-Y)=D(X)+D(Y)$.</p>
协方差矩阵	$\begin{pmatrix} \sigma_{XX} & \sigma_{XY} \\ \sigma_{YX} & \sigma_{YY} \end{pmatrix}$
混合矩	<p>对于随机变量 X 与 Y, 如果有 $E(X^k Y^l)$ 存在, 则称之为 X 与 Y 的 $k+l$ 阶混合原点矩, 记为 ν_{kl}; $k+l$ 阶混合中心矩记为:</p> $u_{kl} = E[(X - E(X))^k (Y - E(Y))^l].$

(6) 协方差的性质

- 一、 $\text{cov}(X, Y) = \text{cov}(Y, X)$;
- 二、 $\text{cov}(aX, bY) = ab \text{cov}(X, Y)$;
- 三、 $\text{cov}(X_1 + X_2, Y) = \text{cov}(X_1, Y) + \text{cov}(X_2, Y)$;
- 四、 $\text{cov}(X, Y) = E(XY) - E(X)E(Y)$.

(7) 独立和不相关

- 一、若随机变量 X 与 Y 相互独立, 则 $\rho_{XY} = 0$; 反之不真。
- 二、若 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则 X 与 Y 相互独立的充要条件是 X 和 Y 不相关。

第五章 大数定律和中心极限定理

(1) 大数定律

切比雪夫大数定律	<p>设随机变量 X_1, X_2, \dots 相互独立, 均具有有限方差, 且被同一常数 C 所界: $D(X_i) < C (i=1, 2, \dots)$, 则对于任意的正数 ε, 有</p> $\lim_{n \rightarrow \infty} P\left(\left \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right < \varepsilon\right) = 1.$ <p>特殊情形: 若 X_1, X_2, \dots 具有相同的数学期望 $E(X_i) = \mu$, 则上式成为</p> $\lim_{n \rightarrow \infty} P\left(\left \frac{1}{n} \sum_{i=1}^n X_i - \mu\right < \varepsilon\right) = 1.$
----------	--

伯努利大数定律	<p>设 μ 是 n 次独立试验中事件 A 发生的次数, p 是事件 A 在每次试验中发生的概率, 则对于任意的正数 ε, 有</p> $\lim_{n \rightarrow \infty} P\left(\left \frac{\mu}{n} - p\right < \varepsilon\right) = 1.$ <p>伯努利大数定律说明, 当试验次数 n 很大时, 事件 A 发生的频率与概率有较大判别的可能性很小, 即</p> $\lim_{n \rightarrow \infty} P\left(\left \frac{\mu}{n} - p\right \geq \varepsilon\right) = 0.$ <p>这就以严格的数学形式描述了频率的稳定性。</p>
辛钦大数定律	<p>设 $X_1, X_2, \dots, X_n, \dots$ 是相互独立同分布的随机变量序列, 且 $E(X_n) = \mu$, 则对于任意的正数 ε 有</p> $\lim_{n \rightarrow \infty} P\left(\left \frac{1}{n} \sum_{i=1}^n X_i - \mu\right < \varepsilon\right) = 1.$

(2) 中心极限定理 $\bar{X} \rightarrow N(\mu, \frac{\sigma^2}{n})$

列维—林德伯格定理	<p>设随机变量 X_1, X_2, \dots 相互独立, 服从同一分布, 且具有相同的数学期望和方差:</p> $E(X_k) = \mu, D(X_k) = \sigma^2 \neq 0 (k=1, 2, \dots),$ <p>则随机变量序列</p> $Y_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$ <p>的分布函数 $F_n(x)$ 对任意的实数 x, 有</p> $\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P\left\{\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq x\right\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt.$ <p>此定理也称为独立同分布的中心极限定理。</p>
棣莫弗—拉普拉斯定理	<p>设随机变量 X_n 为具有参数 $n, p (0 < p < 1)$ 的二项分布, 则对于任意实数 x, 有</p> $\lim_{n \rightarrow \infty} P\left\{\frac{X_n - np}{\sqrt{np(1-p)}} \leq x\right\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt.$

(3) 二项定理

若当 $N \rightarrow \infty$ 时, $\frac{M}{N} \rightarrow p (n, k \text{ 不变})$, 则

$$\frac{C_M^k C_{N-M}^{n-k}}{C_N^n} \rightarrow C_n^k p^k (1-p)^{n-k} \quad (N \rightarrow \infty).$$

即超几何分布的极限分布为二项分布。

(4) 泊松定理

若当 $n \rightarrow \infty$ 时, $np \rightarrow \lambda > 0$, 则

$$C_n^k p^k (1-p)^{n-k} \rightarrow \frac{\lambda^k}{k!} e^{-\lambda} \quad (n \rightarrow \infty).$$

其中 $k=0, 1, 2, \dots, n, \dots$ 。

即二项分布的极限分布为泊松分布。

第六章 样本及抽样分布

(1) 数理统计的基本概念

总体	在数理统计中, 常把被考察对象的某一个(或多个)指标的全体称为总体(或母体)。我们总是把总体看成一个具有分布的随机变量(或随机向量)。
----	---

个体	总体中的每一个单元称为样品（或个体）。
样本	我们把从总体中抽取的部分样品 X_1, X_2, \dots, X_n 称为样本。样本中所含的样品数称为样本容量，一般用 n 表示。在一般情况下，总是把样本看成是 n 个相互独立的且与总体有相同分布的随机变量，这样的样本称为简单随机样本。在具体的的一次抽取之后， x_1, x_2, \dots, x_n 表示 n 个具体的数值（样本值）。
样本函数和统计量	<p>设 X_1, X_2, \dots, X_n 为总体的一个样本，称</p> $\varphi = \varphi(X_1, X_2, \dots, X_n)$ <p>为样本函数，其中 φ 为一个连续函数。如果 φ 中不包含任何未知参数，则称 $\varphi(X_1, X_2, \dots, X_n)$ 为一个统计量。</p>
常见统计量及其性质	<p>样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$.</p> <p>样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$.</p> <p>样本标准差 $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$.</p> <p>样本 k 阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, k=1, 2, \dots$.</p> <p>样本 k 阶中心矩 $M_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k, k=2, 3, \dots$.</p> <p>$E(\bar{X}) = \mu, D(\bar{X}) = \frac{\sigma^2}{n}$,</p> <p>$E(S^2) = \sigma^2, E(M_2) = \frac{n-1}{n} \sigma^2$, 其中 $M_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$.</p>

(2) 正态总体下的四大分布

正态分布	<p>设 X_1, X_2, \dots, X_n 为来自正态总体 $N(\mu, \sigma^2)$ 的一个样本，则样本函数</p> $u \stackrel{\text{def}}{=} \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$
t 分布	<p>设 X_1, X_2, \dots, X_n 为来自正态总体 $N(\mu, \sigma^2)$ 的一个样本，则样本函数</p> $t \stackrel{\text{def}}{=} \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1),$ <p>其中 $t(n-1)$ 表示自由度为 $n-1$ 的 t 分布。</p>
χ^2 分布	<p>设 X_1, X_2, \dots, X_n 为来自正态总体 $N(\mu, \sigma^2)$ 的一个样本，则样本函数</p> $w \stackrel{\text{def}}{=} \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1),$ <p>其中 $\chi^2(n-1)$ 表示自由度为 $n-1$ 的 χ^2 分布。</p>

F 分布	<p>设 X_1, X_2, \dots, X_{n_1} 为来自正态总体 $N(\mu_1, \sigma_1^2)$ 的一个样本, 而 Y_1, Y_2, \dots, Y_{n_2} 为来自正态总体 $N(\mu_2, \sigma_2^2)$ 的一个样本, 则样本函数</p> $F \stackrel{\text{def}}{=} \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1),$ <p>其中</p> $S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (x_i - \bar{x})^2, \quad S_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (y_i - \bar{y})^2;$ <p>$F(n_1 - 1, n_2 - 1)$ 表示第一自由度为 $n_1 - 1$, 第二自由度为 $n_2 - 1$ 的 F 分布。</p>
--------	---

(3) 正态总体下分布的性质

单正态总体 $N(\mu, \sigma^2)$	<p>设 X_1, X_2, \dots, X_n 为来自正态总体 $N(\mu_1, \sigma_1^2)$ 的一个样本, \bar{X} 是其样本均值, S^2 是其样本方差, 则有</p> <p>① \bar{X} 与 S^2 独立; ② $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1);$</p> <p>③ $\frac{n-1}{\sigma^2} S^2 \sim \chi^2(n-1);$ ④ $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1) .$</p>
双正态总体 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$	<p>设 X_1, X_2, \dots, X_{n_1} 为来自正态总体 $N(\mu_1, \sigma_1^2)$ 的一个样本, 而 Y_1, Y_2, \dots, Y_{n_2} 为来自正态总体 $N(\mu_2, \sigma_2^2)$ 的一个样本, \bar{X}, \bar{Y} 是其样本均值, S_1^2, S_2^2 是其样本方差, 则</p> <p>① $F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1);$</p> <p>② 当 $\sigma_1^2 = \sigma_2^2$ 时,</p> $T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$ <p>其中 $S_w = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$</p>

第七章 参数估计

(1) 点估计

无偏性	<p>设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为未知参数 θ 的估计量。若 $E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 为 θ 的无偏估计量。</p> <p>$E(\bar{X}) = E(X), \quad E(S^2) = D(X)$</p>
有效性	<p>设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的两个无偏估计量。若 $D(\hat{\theta}_1) < D(\hat{\theta}_2)$, 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。</p>
一致性	<p>设 $\hat{\theta}$ 是 θ 的一串估计量, 如果对于任意的正数 ε, 都有</p> $\lim_{n \rightarrow \infty} P(\hat{\theta} - \theta > \varepsilon) = 0,$ <p>则称 $\hat{\theta}$ 为 θ 的一致估计量 (或相合估计量)。</p> <p>若 $\hat{\theta}$ 为 θ 的无偏估计, 且 $D(\hat{\theta}) \rightarrow 0 (n \rightarrow \infty)$, 则 $\hat{\theta}$ 为 θ 的一致估计。</p>

(3) 区间估计

置信区间和置信度	<p>设总体 X 含有一个待估的未知参数 θ。如果我们从样本 X_1, X_2, \dots, X_n 出发, 找出两个统计量 $\theta_1 = \theta_1(X_1, X_2, \dots, X_n)$ 与 $\theta_2 = \theta_2(X_1, X_2, \dots, X_n)$ ($\theta_1 < \theta_2$), 使得区间 $[\theta_1, \theta_2]$ 以 $1 - \alpha$ ($0 < \alpha < 1$) 的概率包含这个待估参数 θ, 即</p> $P\{\theta_1 \leq \theta \leq \theta_2\} = 1 - \alpha,$ <p>那么称区间 $[\theta_1, \theta_2]$ 为 θ 的置信区间, $1 - \alpha$ 为该区间的置信度 (或置信水平)。</p>
区间估计的枢轴变量法	<p>设 X_1, X_2, \dots, X_n 为总体 X 的一个样本, x_1, x_2, \dots, x_n 为其一组样本值。在置信度为 $1 - \alpha$ 下, 我们来确定参数 θ 置信区间 $[\theta_1, \theta_2]$。具体步骤如下:</p> <p>(i) 选取待估参数 θ 的估计量; 原则: 优良性准则, 常用: $\bar{X} \rightarrow \mu, \quad S^2 \rightarrow \sigma^2$,</p> <p>(ii) 建立枢轴变量; 对选定的 θ 的估计量, 构造关于待估参数 θ 和样本的函数 $W(X_1, X_2, \dots, X_n, \theta)$, 其中 W 不含任何其他未知参数。</p> <p>(iii) 确定 W 的分布 在一定条件下, W 通常具有经典分布 (主要有正态、χ^2、T、F 分布)。</p> <p>(iv) 根据 W 的分布, 对置信水平 $1 - \alpha$ 查上侧分位数, 使</p> $P\{w_{1-\alpha/2} \leq W \leq w_{\alpha/2}\} = 1 - \alpha$ <p>或类似的概率式成立。</p> <p>(v) 改写不等式得</p> $P\{A \leq \theta \leq B\} = 1 - \alpha$ <p>其中 A、B 是不含未知参数的统计量。</p>

(4) 单正态总体 $N(\mu, \sigma^2)$ 的期望和方差的区间估计

估计均值 μ	已知方差	<p>(i) 选择样本函数 $u = \frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}} \sim N(0, 1)$.</p> <p>(ii) 查表找分位数 $P(-u_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}} \leq u_{\alpha/2}) = 1 - \alpha$.</p> <p>(iii) 导出置信区间 $\left[\bar{X} - u_{\alpha/2} \frac{\sigma_0}{\sqrt{n}}, \bar{X} + u_{\alpha/2} \frac{\sigma_0}{\sqrt{n}} \right]$</p>
------------	------	---

	未知方差	(i) 选择样本函数 $t = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$. (ii) 查表找分位数 $P\left(-t_{\alpha/2}(n-1) \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq t_{\alpha/2}(n-1)\right) = 1 - \alpha$. (iii) 导出置信区间 $\left[\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right]$
估计 方差 σ^2	未知均值	(i) 选择样本函数 $W = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$. (ii) 查表找分位数 $P\left(\chi^2_{1-\alpha/2}(n-1) \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi^2_{\alpha/2}(n-1)\right) = 1 - \alpha$. (iii) 导出 σ^2 的置信区间 $\left[\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)} \right]$
	已知均值	(i) 选择样本函数 $W = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$. (ii) 查表找分位数 $P\left(\chi^2_{1-\alpha/2}(n) \leq \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \leq \chi^2_{\alpha/2}(n)\right) = 1 - \alpha$. (iii) 导出 σ^2 的置信区间 $\left[\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi^2_{\alpha/2}(n)}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi^2_{1-\alpha/2}(n)} \right]$

(5) 双正态总体双正态总体 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的期望差和方差商的区间估计

估计 $\mu_1 - \mu_2$	已知 σ_1^2, σ_2^2	(i) 选择样本函数 $u = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \sim N(0, 1)$. (ii) 查表找分位数 $P\left(-u_{\alpha/2} \leq \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \leq u_{\alpha/2}\right) = 1 - \alpha$. (iii) 导出置信区间 $\left[(\bar{X} - \bar{Y}) - u_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{X} - \bar{Y}) + u_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$
	未知 σ_1^2, σ_2^2 但相等	(i) 选择样本函数 $T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$ 其中 $S_w = \sqrt{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}}$ (ii) 查表找分位数 $P\left(-t_{\alpha/2}(n_1 + n_2 - 2) \leq \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \leq t_{\alpha/2}(n_1 + n_2 - 2)\right) = 1 - \alpha$. (iii) 导出置信区间 $\left[(\bar{X} - \bar{Y}) - t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, (\bar{X} - \bar{Y}) + t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right]$

估计 $\frac{\sigma_2^2}{\sigma_1^2}$	已知 μ_1, μ_2	<p>(i) 选择样本函数 $F = \frac{\frac{1}{n_1} \sum_{i=1}^{n_1} \frac{(X_i - \mu_1)^2}{\sigma_1^2}}{\frac{1}{n_2} \sum_{j=1}^{n_2} \frac{(Y_j - \mu_2)^2}{\sigma_2^2}} \sim F(n_1, n_2)$.</p> <p>(ii) 查表找分位数</p> $P \left(F_{1-\alpha/2}(n_1, n_2) \leq \frac{\frac{1}{n_1} \sum_{i=1}^{n_1} \frac{(X_i - \mu_1)^2}{\sigma_1^2}}{\frac{1}{n_2} \sum_{j=1}^{n_2} \frac{(Y_j - \mu_2)^2}{\sigma_2^2}} \leq F_{\alpha/2}(n_1, n_2) \right) = 1 - \alpha.$ <p>(iii) 导出 $\frac{\sigma_2^2}{\sigma_1^2}$ 的置信区间</p> $\left[\frac{\frac{1}{n_2} \sum_{j=1}^{n_2} (Y_j - \mu_2)^2}{\frac{1}{n_1} \sum_{i=1}^{n_1} (X_i - \mu_1)^2} F_{1-\alpha/2}(n_1, n_2), \frac{\frac{1}{n_2} \sum_{j=1}^{n_2} (Y_j - \mu_2)^2}{\frac{1}{n_1} \sum_{i=1}^{n_1} (X_i - \mu_1)^2} F_{\alpha/2}(n_1, n_2) \right]$
	未知 μ_1, μ_2	<p>(i) 选择样本函数 $D = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$.</p> <p>(ii) 查表找分位数</p> $P \left\{ F_{1-\alpha/2}(n_1 - 1, n_2 - 1) \leq \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \leq F_{\alpha/2}(n_1 - 1, n_2 - 1) \right\} = 1 - \alpha.$ <p>(iii) 导出 $\frac{\sigma_2^2}{\sigma_1^2}$ 的置信区间</p> $\left[\frac{S_2^2}{S_1^2} F_{1-\alpha/2}(n_1 - 1, n_2 - 1), \frac{S_2^2}{S_1^2} F_{\alpha/2}(n_1 - 1, n_2 - 1) \right]$
	已知 μ_1 未知 μ_2	<p>(i) 选择样本函数 $D = \frac{\frac{1}{n_1} \sum_{i=1}^{n_1} \frac{(X_i - \mu_1)^2}{\sigma_1^2}}{S_2^2/\sigma_2^2} \sim F(n_1, n_2 - 1)$.</p> <p>(ii) 查表找分位数</p> $P \left\{ F_{1-\alpha/2}(n_1, n_2 - 1) \leq \frac{\frac{1}{n_1} \sum_{i=1}^{n_1} \frac{(X_i - \mu_1)^2}{\sigma_1^2}}{S_2^2/\sigma_2^2} \leq F_{\alpha/2}(n_1, n_2 - 1) \right\} = 1 - \alpha.$ <p>(iii) 导出 $\frac{\sigma_2^2}{\sigma_1^2}$ 的置信区间</p> $\left[\frac{S_2^2}{\frac{1}{n_1} \sum_{i=1}^{n_1} (X_i - \mu_1)^2} F_{1-\alpha/2}(n_1, n_2 - 1), \frac{S_2^2}{\frac{1}{n_1} \sum_{i=1}^{n_1} (X_i - \mu_1)^2} F_{\alpha/2}(n_1, n_2 - 1) \right]$

未知 μ_1 已知 μ_2	<p>(i) 选择样本函数 $D = \frac{S_1^2/\sigma_1^2}{\frac{1}{n_2} \sum_{j=1}^{n_2} \frac{(Y_j - \mu_2)^2}{\sigma_2^2}} \sim F(n_1 - 1, n_2)$.</p> <p>(ii) 查表找分位数</p> $P \left\{ F_{1-\alpha/2}(n_1 - 1, n_2) \leq \frac{S_1^2/\sigma_1^2}{\frac{1}{n_2} \sum_{j=1}^{n_2} \frac{(Y_j - \mu_2)^2}{\sigma_2^2}} \leq F_{\alpha/2}(n_1 - 1, n_2) \right\} = 1 - \alpha.$ <p>(iii) 导出 $\frac{\sigma_2^2}{\sigma_1^2}$ 的置信区间</p> $\left[\frac{\frac{1}{n_2} \sum_{j=1}^{n_2} \frac{(Y_j - \mu_2)^2}{\sigma_2^2}}{S_1^2} F_{1-\alpha/2}(n_1 - 1, n_2), \frac{\frac{1}{n_2} \sum_{j=1}^{n_2} \frac{(Y_j - \mu_2)^2}{\sigma_2^2}}{S_1^2} F_{\alpha/2}(n_1 - 1, n_2) \right]$
--------------------------	---

第八章 假设检验

基本思想	<p>假设检验的统计思想是，概率很小的事件在一次试验中可以认为基本上是不会发生的，即小概率原理。</p> <p>为了检验一个假设 H_0 是否成立。我们先假定 H_0 是成立的。如果根据这个假定导致了一个不合理的事件发生，那就表明原来的假定 H_0 是不正确的，我们拒绝接受 H_0；如果由此没有导出不合理的现象，则不能拒绝接受 H_0，我们称 H_0 是相容的。与 H_0 相对的假设称为备择假设，用 H_1 表示。</p> <p>这里所说的小概率事件就是事件 $\{K \in R_\alpha\}$，其概率就是检验水平 α，通常我们取 $\alpha = 0.05$，有时也取 0.01 或 0.10。</p>	
基本步骤	<p>假设检验的基本步骤如下：</p> <p>(i) 提出零假设 H_0；</p> <p>(ii) 选择统计量 K；</p> <p>(iii) 对于检验水平 α 查表找分位数 λ；</p> <p>(iv) 由样本值 x_1, x_2, \dots, x_n 计算统计量之值 \hat{K}；</p> <p>将 \hat{K} 与 λ 进行比较，作出判断：当 $\hat{K} > \lambda$ (或 $\hat{K} > \lambda$) 时否定 H_0，否则认为 H_0 相容。</p>	
两类错误	第一类错误	<p>当 H_0 为真时，而样本值却落入了否定域，按照我们规定的检验法则，应当否定 H_0。这时，我们把客观上 H_0 成立判为 H_0 为不成立（即否定了真实的假设），称这种错误为“以真当假”的错误或第一类错误，记 α 为犯此类错误的概率，即 $P\{\text{否定 } H_0 H_0 \text{ 为真}\} = \alpha$；</p> <p>此处的 α 恰好为检验水平。</p>
	第二类错误	<p>当 H_1 为真时，而样本值却落入了相容域，按照我们规定的检验法则，应当接受 H_0。这时，我们把客观上 H_0 不成立判为 H_0 成立（即接受了不真实的假设），称这种错误为“以假当真”的错误或第二类错误，记 β 为犯此类错误的概率，即 $P\{\text{接受 } H_0 H_1 \text{ 为真}\} = \beta$。</p>

	两类错误的关系	<p>人们当然希望犯两类错误的概率同时都很小。但是，当容量 n 一定时，α 变小，则 β 变大；相反地，β 变小，则 α 变大。取定 α 要想使 β 变小，则必须增加样本容量。</p> <p>在实际使用时，通常人们只能控制犯第一类错误的概率，即给定显著性水平 α。α 大小的选取应根据实际情况而定。当我们宁可“以假为真”、而不愿“以真当假”时，则应把 α 取得很小，如 0.01，甚至 0.001。反之，则应把 α 取得大些。</p>
--	---------	---

单正态总体 $N(\mu, \sigma^2)$ 的均值和方差的假设检验

条件	零假设	统计量	对应样本函数分布	否定域
已知 σ^2	$H_0: \mu = \mu_0$	$U = \frac{\bar{X} - \mu_0}{\sigma_0 / \sqrt{n}}$	$N(0, 1)$	$ u > u_{1-\frac{\alpha}{2}}$
	$H_0: \mu \leq \mu_0$			$u > u_\alpha$
	$H_0: \mu \geq \mu_0$			$u < u_{1-\alpha}$
未知 σ^2	$H_0: \mu = \mu_0$	$T = \frac{\bar{X} - \mu_0}{S / \sqrt{n}}$	$t(n-1)$	$ t > t_{1-\frac{\alpha}{2}}(n-1)$
	$H_0: \mu \leq \mu_0$			$t > t_\alpha(n-1)$
	$H_0: \mu \geq \mu_0$			$t < t_{1-\alpha}(n-1)$
未知 μ	$H_0: \sigma^2 = \sigma_0^2$	$W = \frac{(n-1)S^2}{\sigma_0^2}$	$\chi^2(n-1)$	$w > \chi_{\frac{\alpha}{2}}^2(n-1)$ 或 $w < \chi_{1-\frac{\alpha}{2}}^2(n-1)$
	$H_0: \sigma^2 \leq \sigma_0^2$			$w > \chi_\alpha^2(n-1)$
	$H_0: \sigma^2 \geq \sigma_0^2$			$w < \chi_{1-\alpha}^2(n-1)$
已知 μ	$H_0: \sigma^2 = \sigma_0^2$	$W = \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma_0^2}$	$\chi^2(n)$	$w < \chi_{\frac{\alpha}{2}}^2(n)$ 或 $w > \chi_{1-\frac{\alpha}{2}}^2(n)$
	$H_0: \sigma^2 \leq \sigma_0^2$			$w > \chi_\alpha^2(n)$
	$H_0: \sigma^2 \geq \sigma_0^2$			$w < \chi_{1-\alpha}^2(n)$

双正态总体 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ 的均值和方差的假设检验

条件	零假设	统计量	对应样本	否定域
----	-----	-----	------	-----

			函数分布	
已知 σ_1^2, σ_2^2	$H_0: \mu_1 = \mu_2$	$U = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_1^2/n_2}}$	$N(0,1)$	$ u > u_{1-\frac{\alpha}{2}}$
	$H_0: \mu_1 \leq \mu_2$			$u > u_\alpha$
	$H_0: \mu_1 \geq \mu_2$			$u < u_{1-\alpha}$
未知 σ_1^2, σ_2^2 但 $\sigma_1^2 = \sigma_2^2$	$H_0: \mu_1 = \mu_2$	$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w / \sqrt{1/n_1 + 1/n_2}}$ $S_w = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2}$	$t(n_1 + n_2 - 2)$	$ t > t_{1-\frac{\alpha}{2}}(n_1 + n_2 - 2)$
	$H_0: \mu_1 \leq \mu_2$			$t > t_\alpha(n_1 + n_2 - 2)$
	$H_0: \mu_1 \geq \mu_2$			$t < t_{1-\alpha}(n_1 + n_2 - 2)$
未知 μ_1, μ_2	$H_0: \sigma_1^2 = \sigma_2^2$	$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}$	$F(n_1 - 1, n_2 - 1)$	$f < F_{1-\frac{\alpha}{2}}(n_1 - 1, n_2 - 1)$ 或 $f > F_{\frac{\alpha}{2}}(n_1 - 1, n_2 - 1)$
	$H_0: \sigma_1^2 \leq \sigma_2^2$			$f > F_\alpha(n_1 - 1, n_2 - 1)$
	$H_0: \sigma_1^2 \geq \sigma_2^2$			$f < F_{1-\alpha}(n_1 - 1, n_2 - 1)$
已知 μ_1, μ_2	$H_0: \sigma^2 = \sigma^2$	$F = \frac{\frac{1}{n_1} \sum_{i=1}^{n_1} (X_i - \mu_1)^2 / \sigma_1^2}{\frac{1}{n_2} \sum_{j=1}^{n_2} (Y_j - \mu_2)^2 / \sigma_2^2}$	$F(n_1, n_2)$	$f < F_{1-\frac{\alpha}{2}}(n_1, n_2)$ 或 $f > F_{\frac{\alpha}{2}}(n_1, n_2)$
	$H_0: \sigma^2 \leq \sigma_0^2$			$f > F_\alpha(n_1, n_2)$
	$H_0: \sigma^2 \geq \sigma_0^2$			$f < F_{1-\alpha}(n_1, n_2)$
已知 μ_1 , 未知 μ_2	$H_0: \sigma^2 = \sigma^2$	$F = \frac{S_1^2/\sigma_1^2}{\frac{1}{n_2} \sum_{j=1}^{n_2} \frac{(Y_j - \mu_2)^2}{\sigma_2^2}}$	$F(n_1 - 1, n_2)$	$f < F_{1-\frac{\alpha}{2}}(n_1 - 1, n_2)$ 或 $f > F_{\frac{\alpha}{2}}(n_1 - 1, n_2)$
	$H_0: \sigma^2 \leq \sigma_0^2$			$f > F_\alpha(n_1 - 1, n_2)$
	$H_0: \sigma^2 \geq \sigma_0^2$			$f < F_{1-\alpha}(n_1 - 1, n_2)$
未知 μ_1 , 已知 μ_2	$H_0: \sigma^2 = \sigma^2$	$F = \frac{\frac{1}{n_1} \sum_{i=1}^{n_1} \frac{(X_i - \mu_1)^2}{\sigma_1^2}}{S_2^2/\sigma_2^2}$	$F(n_1, n_2 - 1)$	$f < F_{1-\frac{\alpha}{2}}(n_1, n_2 - 1)$ 或 $f > F_{\frac{\alpha}{2}}(n_1, n_2 - 1)$
	$H_0: \sigma^2 \leq \sigma_0^2$			$f > F_\alpha(n_1, n_2 - 1)$
	$H_0: \sigma^2 \geq \sigma_0^2$			$f < F_{1-\alpha}(n_1, n_2 - 1)$

第九章 回归分析

(1) 一元线性回归模型

$$Y=a+bx+\varepsilon, \quad \varepsilon \sim N(0, \sigma^2)$$

其中 a 、 b 、 σ^2 为未知参数，称 a — 回归常数(又称截距)， b — 回归系数(又称斜率)， ε — 随机误差（随机扰动项）。

(2) 一元线性回归模型的参数估计

$$\begin{cases} \hat{b} = \frac{l_{xy}}{l_{xx}} \\ \hat{a} = \bar{y} - \hat{b}\bar{x} \end{cases}$$

其中

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

$$l_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}$$

$$l_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$$

(3) 对 σ^2 的无偏估计为：

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n-2} \sum_{i=1}^n (l_{yy} - \hat{b}^2 l_{xx})$$

其中
$$l_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2$$

(4) 一元线性回归模型的显著性检验，样本相关系数为

$$R = \frac{l_{xy}}{\sqrt{l_{xx}} \sqrt{l_{yy}}}$$